รายงานสรุปข้อสอบปลายภาค · วิชา 02739452

ระบบวิเคราะห์ความนิยมและคะแนนเข้าหลักสูตรปริญญาตรี มหาวิทยาลัยเกษตรศาสตร์

นายณัฐภัทร ยืนยง รหัสนิสิต 6621655231 · หมู่ 820 · ลำดับที่ 22

Repository: **https://github.com/Catboyz-45/02739452-22-6621655231** · วิธีรัน: `cp .env.example .env` แล้ว `docker compose up -d --build` (Airflow พอร์ต 8080, Dashboard พอร์ต 8501)

1 ภาพรวมของงาน

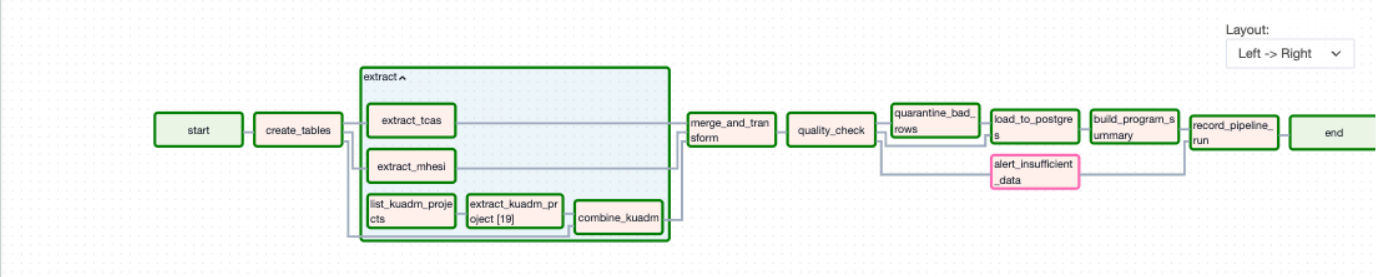
ระบบรวบรวมข้อมูลการรับเข้าศึกษาของ ม.เกษตรศาสตร์ จาก 3 หน่วยงาน ผ่าน Apache Airflow แล้วจัดเก็บใน PostgreSQL เพื่อตอบคำถามว่า **หลักสูตรใดมีผู้สนใจมากที่สุด แข่งขันสูงเพียงใด และต้องใช้คะแนนเท่าไร** ผลลัพธ์แสดงผ่าน Dashboard ที่อ่านข้อมูลจาก PostgreSQL โดยตรง

3	1,917	264	~25 วินาที
แหล่งข้อมูล (scraping 2 แหล่ง)	แถวในตารางหลัก	หลักสูตร หลังตัดข้อมูลซ้ำ	เวลารัน DAG ต่อรอบ

แหล่งข้อมูล	วิธีดึงข้อมูล	ข้อมูลที่ได้ (เฉพาะ มก.)	จำนวนแถว
1. ทปอ. (mytcas.com)	**Web scraping** หน้าสถิติด้วย BeautifulSoup เพื่อหาลิงก์ไฟล์ แล้วดาวน์โหลด Excel	สถิติ TCAS รอบ 3 ปี 2567–2569: จำนวนรับ ผู้สมัคร คะแนนต่ำสุด–สูงสุด	1,017
2. สป.อว. (data.go.th)	CKAN API ค้นหาลิงก์ไฟล์ แล้วดาวน์โหลด CSV	จำนวนนักศึกษาใหม่ ป.ตรี ปี 2567 (รวมยอดชาย–หญิงเป็นยอดต่อหลักสูตร)	182
3. admission.ku.ac.th	**Web scraping** ตาราง HTML ของ 19 โครงการด้วย Dynamic Task Mapping	จำนวนรับ TCAS ปี 2570 แยกตามโครงการและสาขา	762

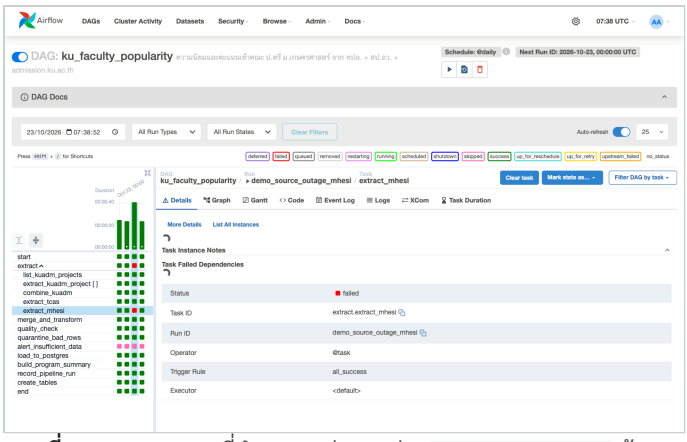
ระดับ	สิ่งที่ทำและหลักฐาน	ผล
ระดับ 1	DAG ทำงานครบ Extract → Transform → Load ลง PostgreSQL · Dashboard (Streamlit) อ่านจากฐานข้อมูลโดยตรง แสดงทั้งตารางและกราฟ	ครบ
ระดับ 2	ดึง 3 แหล่งพร้อมกันใน TaskGroup `extract` และแปลงเป็น schema เดียว (`admission_stats`) · โหลดแบบ **UPSERT** ด้วยคีย์ (source, academic_year, source_record_id) รันซ้ำแล้วจำนวนแถวยังเท่าเดิม · Dashboard มี KPI 4 ตัว ตัวกรอง 5 แบบ และช่องกรอกคะแนนของผู้ใช้	ครบ
ระดับ 3	**ทนต่อแหล่งข้อมูลล่ม:** ขั้น `merge_and_transform` ใช้ `trigger_rule=all_done` ทดสอบโดยจำลองให้แหล่ง อว. ล่ม ระบบยังโหลดได้ 1,735 แถว และบันทึกสถานะเป็น partial **ตัดข้อมูลซ้ำข้ามแหล่ง:** จับคู่ด้วยวิทยาเขต + ชื่อสาขาที่ปรับให้เป็นมาตรฐาน (`major_key`) ได้ 264 หลักสูตร โดย 214 หลักสูตรพบตั้งแต่ 2 แหล่งขึ้นไป **ตรวจคุณภาพและแยกเส้นทาง (Branch):** ผ่านทั้งหมด → โหลด · พบแถวผิดปกติ → แยกไปตาราง `dq_quarantine` แล้วโหลดส่วนที่เหลือ · ข้อมูลน้อยกว่า 100 แถว → แจ้งเตือนและไม่เขียนทับข้อมูลเดิม	ครบ
โบนัส	Dynamic Task Mapping (`extract_kuadm_project.expand()` สร้าง 19 task) และหน้า "สถานะ Pipeline" บนเว็บ	ครบ

จริยธรรมข้อมูล: ไม่ใช้ Selenium · ตรวจ robots.txt ทุกเว็บก่อนดึง (data.mhesi.go.th ไม่อนุญาต `/api/` จึงใช้ API ของ data.go.th แทน) · หน่วงเวลา 1 วินาทีต่อคำขอ · ข้อมูลทั้งหมดเป็นสถิติภาพรวม ไม่มีข้อมูลส่วนบุคคล (PDPA)

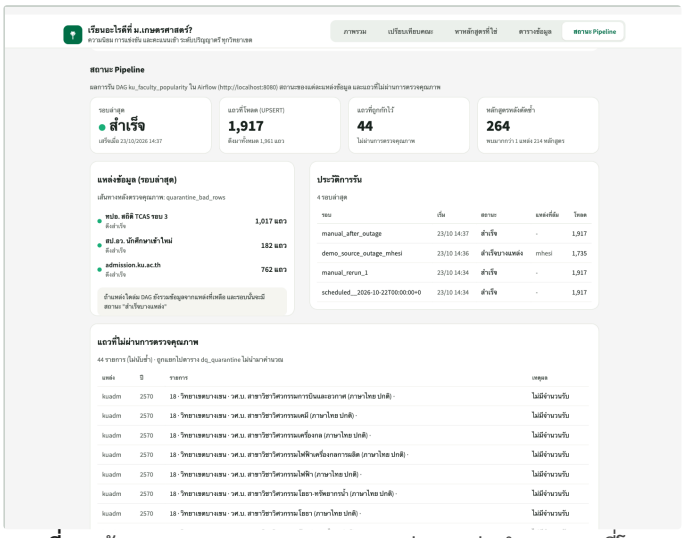


ภาพที่ 1 โครงสร้าง DAG `ku_faculty_popularity` (Graph view): ดึง 3 แหล่งขนานกัน → รวมและแปลงข้อมูล → ตรวจคุณภาพ → โหลด → สรุปผล → บันทึกการรัน

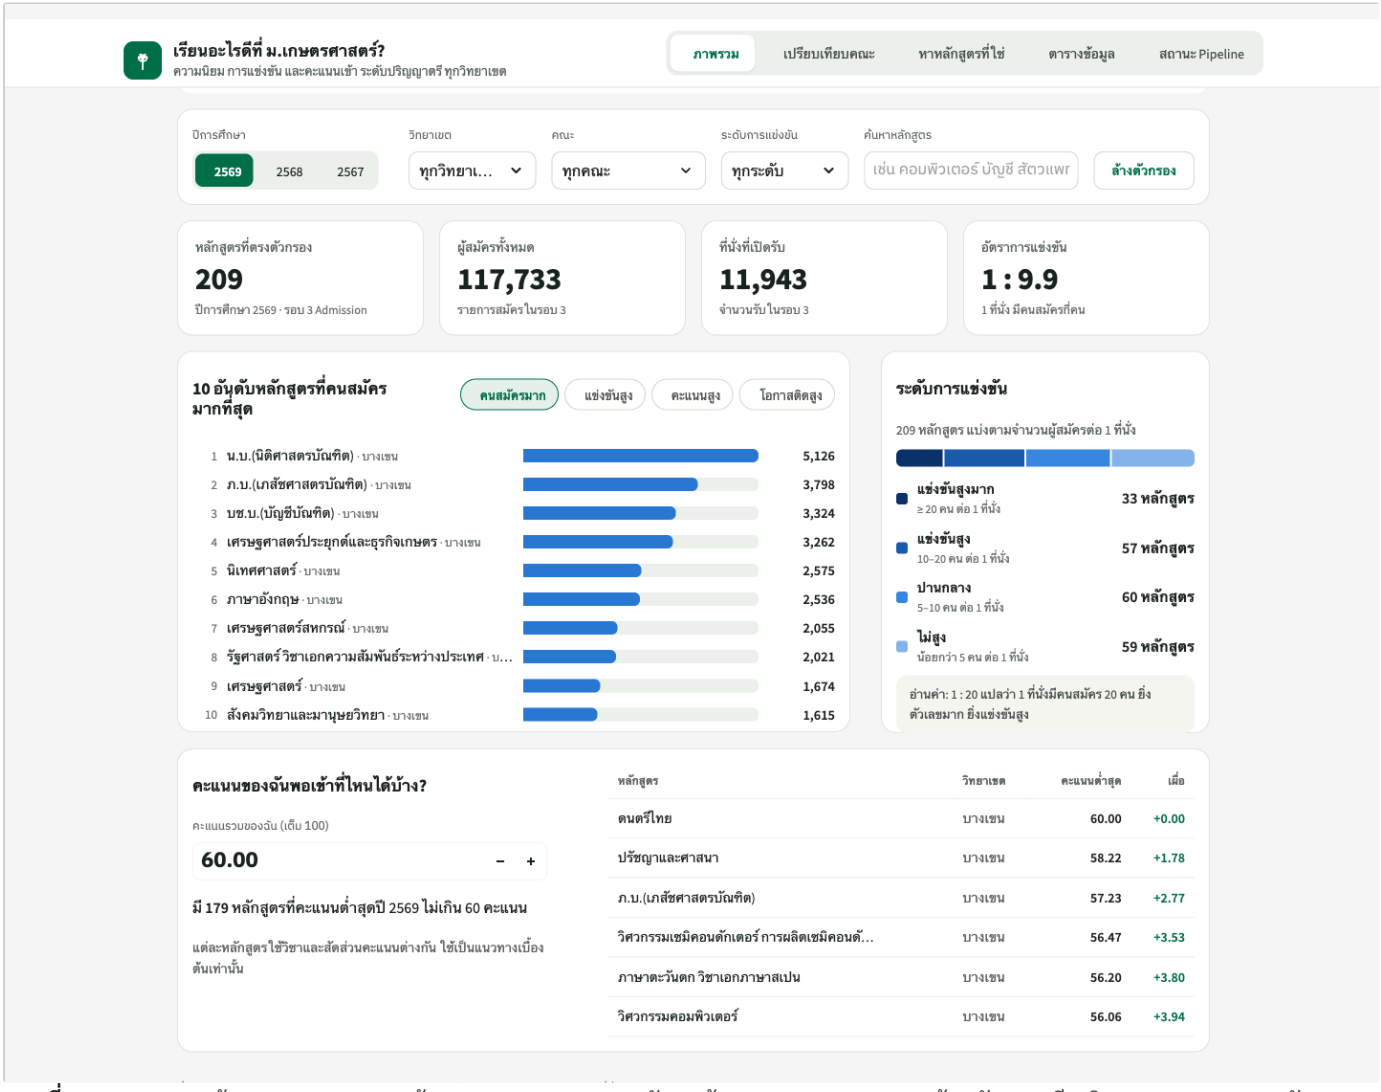
2 ผลการทำงานของระบบ



ภาพที่ 2 Grid view รอบที่จำลองแหล่ง อว. ล่ม: `extract_mhesi` ล้มเหลว (สีแดง) แต่ขั้นตอนถัดไปยังทำงานต่อและโหลดข้อมูลจาก 2 แหล่งที่เหลือ



ภาพที่ 3 หน้าสถานะ Pipeline: สถานะของแต่ละแหล่ง จำนวนแถวที่โหลด/ถูกแยกออก และประวัติการรัน



ภาพที่ 4 Dashboard หน้าภาพรวม (ออกแบบด้วย Claude Design และพัฒนาด้วย Streamlit): เมนู 5 หน้า · ตัวกรอง ปี / วิทยาเขต / คณะ / ระดับการแข่งขัน / ค้นหา · KPI 4 ตัว · จัดอันดับหลักสูตรได้ 4 มุมมอง · สัดส่วนระดับการแข่งขัน · และส่วน "คะแนนของฉันพอเข้าที่ไหนได้บ้าง" หน้าอื่นประกอบด้วย เปรียบเทียบคณะ, รายละเอียดรายหลักสูตร, ตารางข้อมูลพร้อมดาวน์โหลด CSV และสถานะ Pipeline

3 ปัญหาที่พบและแนวทางแก้ไข

3.1 พื้นที่ดิสก์เต็มระหว่าง build image ของ Airflow

อาการ คำสั่ง `docker compose up --build` ล้มเหลว (*input/output error*) จากนั้น Docker daemon หยุดทำงาน และทุกคำสั่งแจ้ง *ENOSPC*

หาสาเหตุ `df -h` พบพื้นที่เหลือ 0 B · `du -sh` พบไฟล์ Docker.raw ขนาด 30 GB · `docker system df` พบ image ที่ไม่ใช้งาน 7.9 GB

แก้ไข ล้าง cache ที่สร้างใหม่ได้ และรัน `docker image prune -a` กับ `builder prune` ได้พื้นที่คืน 10.6 GB · เลือกใช้ LocalExecutor และ image เดียวร่วมกันเพื่อลดขนาด

3.2 ไฟล์ Excel ของ ทปอ. แต่ละปีมีโครงสร้างไม่เหมือนกัน

อาการ ชื่อคอลัมน์คะแนนต่างกันในแต่ละปี (ปี 2569 มีคอลัมน์ "DS" และ "รหัสโครงการ" เพิ่ม) และข้อมูลเขียนทับกันเมื่อ UPSERT

หาสาเหตุ เปรียบเทียบ header ของทุกไฟล์ และนับรหัสหลักสูตรที่ซ้ำ (ปี 2569 ซ้ำ 56 รหัส)

แก้ไข เลือกคอลัมน์ด้วยคำสำคัญและใช้ผลการประมวลผลรอบสุดท้าย · กำหนด `source_record_id` = รหัสหลักสูตร | รายละเอียด | วิชาเอก | รหัสโครงการ

3.3 ชื่อหลักสูตรไม่ตรงกันระหว่างแหล่งข้อมูล

อาการ "น.บ.(นิติศาสตรบัณฑิต)" จาก ทปอ. ไม่ถูกจับคู่กับ "นิติศาสตร์" จาก อว. ทำให้หลักสูตรเดียวกันแยกเป็น 2 แถว

หาสาเหตุ ค้นหาแถวในตารางสรุปที่พบเพียง 1 แหล่ง (`n_sources = 1`) แต่ชื่อใกล้เคียงกับแถวอื่น

แก้ไข ปรับฟังก์ชัน `major_key` ให้ใช้ชื่อหลังคำว่า "สาขาวิชา" หรือชื่อปริญญาในวงเล็บ และตัดคำว่า "บัณฑิต" ช่องว่าง และไม้ทัณฑฆาต ทำให้หลักสูตรที่จับคู่ได้ตั้งแต่ 2 แหล่งเพิ่มเป็น 214 หลักสูตร

3.4 ช่องจำนวนรับไม่ใช่ตัวเลข

อาการ 44 แถวจาก admission.ku.ac.th ระบุว่า "*จำนวนรับรวมกับเงื่อนไขอื่น" แทนตัวเลข

หาสาเหตุ ตรวจเหตุผลในตาราง `dq_quarantine` และเปิด HTML ของหน้าโครงการต้นทาง

แก้ไข เพิ่มกฎตรวจคุณภาพ "ต้องมีจำนวนรับ" และแยกแถวเหล่านี้ออกไม่นำมาคำนวณ เพื่อป้องกันการนับที่นั่งซ้ำ

4 การวางแผนและจัดลำดับงาน

ช่วงเวลา	งานที่ทำ
13:00–13:55	วิเคราะห์โจทย์และแตกเป็นรายการตามระดับ · สำรวจแหล่งข้อมูลจริงก่อนจองหัวข้อ (robots.txt, รูปแบบหน้าเว็บ, จำนวนแถว) · เลือกหัวข้อที่ทั้ง 3 แหล่งเป็นเรื่องเดียวกัน
14:00–14:10	สร้าง repository และ push commit แรกทันที · เขียนส่วนดึงข้อมูล 3 แหล่ง และทดสอบนอก Docker ก่อนเพื่อลดเวลาแก้ไขใน Airflow
14:10–14:45	พัฒนาส่วน Transform, ตรวจคุณภาพ, UPSERT และ Dashboard ควบคู่กับแก้ปัญหาดิสก์เต็ม · รัน DAG จริง ทดสอบรันซ้ำ และจำลองแหล่งข้อมูลล่ม
14:45–15:45	ออกแบบ Dashboard ใหม่ด้วย Claude Design และปรับให้ตรงแบบ · เขียน README และรายงาน · clone repository ใหม่เพื่อทดสอบการรันตั้งแต่ต้น

หลักการจัดลำดับ: ทำระดับ 1 ให้ทำงานได้ครบทั้งระบบก่อน จากนั้นจึงเพิ่มระดับ 2, 3 และโบนัสตามลำดับ **งานที่ตัดออกและเหตุผล:**

- **ข้อมูลตลาดงาน (JobThai/JobBKK):** ไม่ใช่เรื่องเดียวกับข้อมูลการรับเข้า และต้องสร้างตารางจับคู่สาขากับอาชีพเอง ใช้เวลามาก
- **สถิติของสำนักบริหารการศึกษา มก.:** แสดงผลด้วย Power BI ต้องใช้ browser automation ซึ่งโจทย์ไม่อนุญาต
- **ข้อมูลย้อนหลังก่อนปี 2567:** โครงสร้างไฟล์แตกต่างกันมาก ข้อมูล 3 ปีเพียงพอต่อการดูแนวโน้ม จึงเก็บไว้เป็นงานต่อยอด