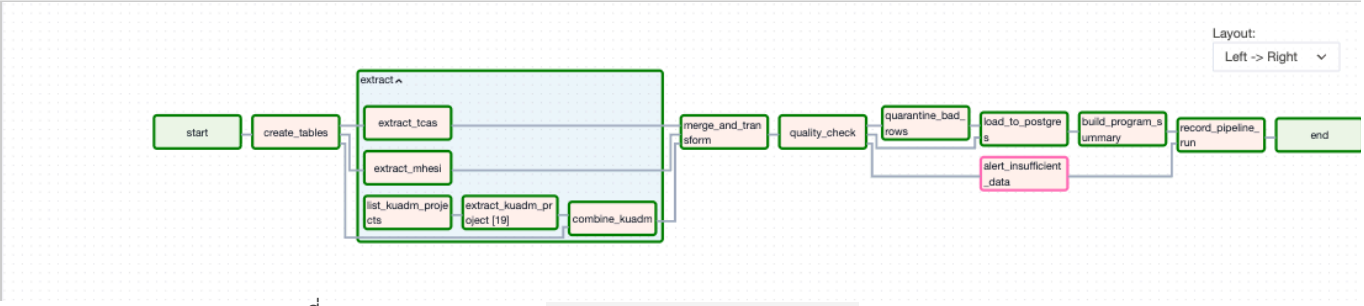
ความนิยมและคะแนนเข้าคณะ ป.ตรี ม.เกษตรศาสตร์

ข้อสอบปลายภาค 02739452 · นายณัฐภัทร ยืนยง รหัส 6621655231 หมู่ 820 ลำดับที่ 22
GitHub: **https://github.com/Catboyz-45/02739452-22-6621655231** (public) · รัน: `cp .env.example .env && docker compose up -d --build` → Airflow :8080 · Dashboard :8501

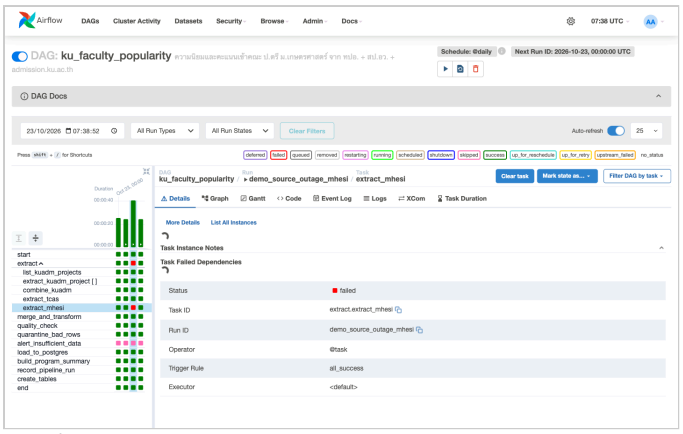
1. ภาพรวมงาน — ทำได้ครบระดับ 1, 2, 3 และโบนัสทั้งสองแบบ

แหล่ง	วิธีดึง	ข้อมูลที่ได้ (เฉพาะ มก.)	แถว
1. ทปอ.	**Web scraping** หน้า mytcas.com/stat (BeautifulSoup) หาลิงก์ไฟล์ แล้วดาวน์โหลด Excel	สถิติ TCAS รอบ 3 ปี 2567–2569: จำนวนรับ ผู้สมัคร คะแนนต่ำสุด/สูงสุด	1,017
2. สป.อว.	CKAN API ของ data.go.th หาลิงก์ไฟล์ → ดาวน์โหลด CSV	นักศึกษาเข้าใหม่ ป.ตรี 2567 (รวมยอดที่แยกเพศให้เป็นยอดต่อหลักสูตร)	182
3. admission.ku.ac.th	**Web scraping** ตาราง HTML 19 โครงการ ด้วย Dynamic Task Mapping	จำนวนรับ TCAS70 แยกโครงการ/สาขา	762

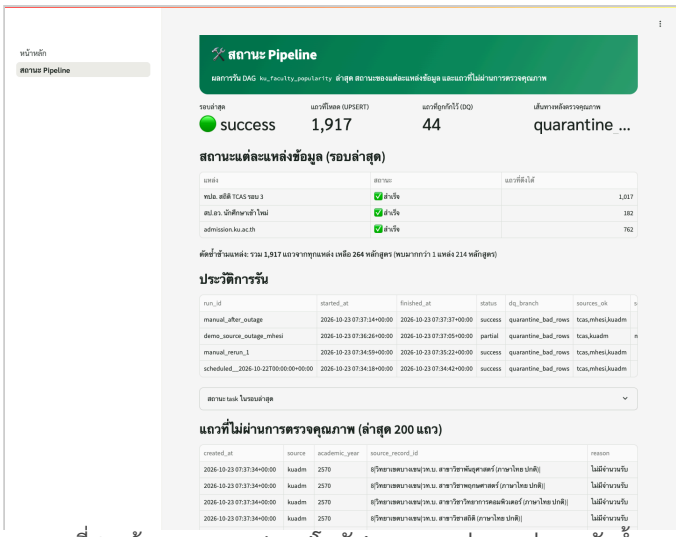
- **ระดับ 1:** DAG extract → transform → load ลง PostgreSQL และ dashboard (Streamlit) อ่านจาก PostgreSQL โดยตรง แสดงตาราง + กราฟ
- **ระดับ 2:** 3 แหล่งรันขนานกันใน TaskGroup `extract` แปลงเป็น schema เดียว (`admission_stats`) ใช้ **UPSERT** คีย์ (source, academic_year, source_record_id) — trigger ซ้ำแล้วยังได้ 1,917 แถวเท่าเดิม · dashboard มี KPI 4 ตัว + ตัวกรอง 6 แบบ (ปี, วิทยาเขต, คณะ, ระดับการแข่งขัน, ช่วงคะแนน, ค้นหาชื่อ)
- **ระดับ 3:** `merge_and_transform` ใช้ `trigger_rule=all_done` แหล่งไหนล่มก็รวมจากแหล่งที่เหลือ (ทดสอบจริงด้วย Variable `kupop_simulate_down=mhesi` ได้สถานะ partial โหลด 1,735 แถว) · **ตัดซ้ำข้ามแหล่ง**: จับคู่หลักสูตรด้วย วิทยาเขต + `major_key` รวม 1,917 แถว เหลือ **264 หลักสูตร** (พบ ≥2 แหล่ง 214, ครบ 3 แหล่ง 136) · **ตรวจคุณภาพ** แล้วแยกเส้นทางด้วย Branch: ผ่านทั้งหมด → load, มีแถวเสีย → `quarantine_bad_rows` แล้ว load, ข้อมูล <100 แถว → `alert_insufficient_data` ไม่โหลดทับข้อมูลเดิม
- **โบนัส:** Dynamic Task Mapping (`extract_kuadm_project.expand()` 19 task) และหน้า "สถานะ Pipeline" บนเว็บ (อ่านจากตาราง `pipeline_runs`, `dq_quarantine`)
- ไม่ใช้ Selenium, ตรวจ robots.txt ทุกเว็บ (data.mhesi.go.th ห้าม `/api/` จึงใช้ API ของ data.go.th แทน), เป็นข้อมูลสถิติรวม ไม่มีข้อมูลส่วนบุคคล



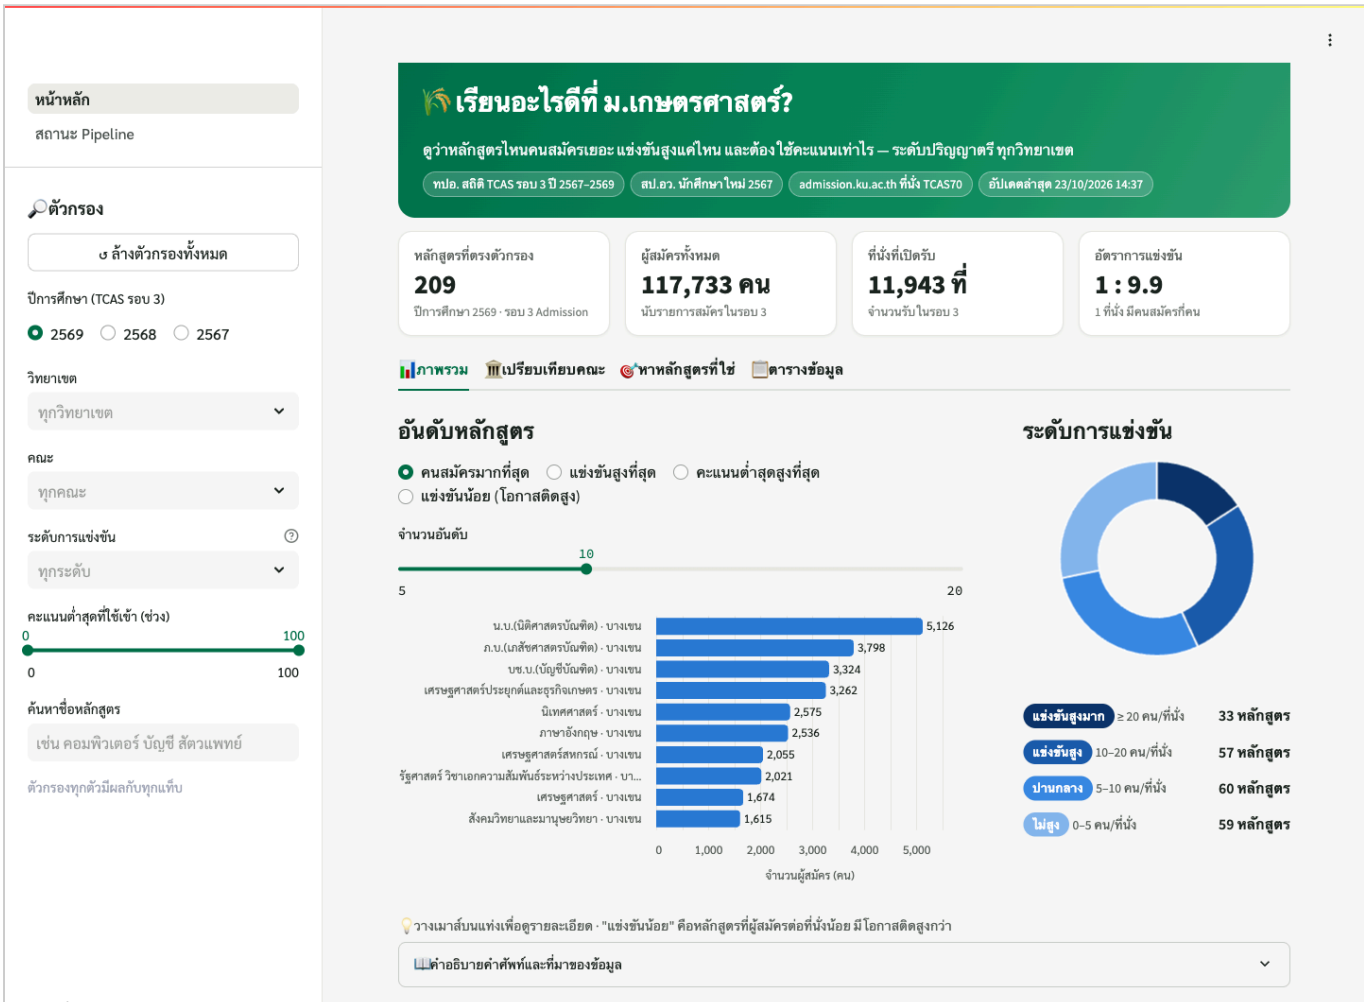
ภาพที่ 1 Graph view ของ DAG `ku_faculty_popularity` (กาง TaskGroup extract)



ภาพที่ 2 Grid view — รอบ `demo_source_outage_mhesi` จำลองแหล่ง อว. ล่ม: extract_mhesi สีแดง แต่ task ถัดไปยังรันต่อ และโหลดจาก 2 แหล่งที่เหลือ



ภาพที่ 3 หน้าสถานะ Pipeline (โบนัส): สถานะแต่ละแหล่ง, ผลตัดซ้ำ, ประวัติการรัน (มีรอบ partial)



ภาพที่ 4 Dashboard (Streamlit อ่านจาก PostgreSQL โดยตรง): ตัวกรอง 6 แบบด้านซ้าย (ปี, วิทยาเขต, คณะ, ระดับการแข่งขัน, ช่วงคะแนน, ค้นหา) · KPI 4 ตัว · 4 แท็บ: ภาพรวม (จัดอันดับได้ 4 แบบ + ระดับการแข่งขัน), เปรียบเทียบคณะ (แนวโน้ม 3 ปี, สมัคร vs เข้าเรียนจริง), หาหลักสูตรที่ใช่ (ใส่คะแนนของตัวเองแล้วดูว่าเข้าหลักสูตรไหนได้ + รายละเอียดรายหลักสูตร), ตารางข้อมูล + ดาวน์โหลด CSV

2. ปัญหาที่พบและวิธีแก้

ปัญหา	อาการ	วิธีหาสาเหตุ	วิธีแก้
1. ดิสก์เต็มระหว่าง build image Airflow	`docker compose up --build` ล้มด้วย *commit failed: input/output error* จากนั้น Docker daemon ล่ม และทุกคำสั่งขึ้น *ENOSPC*	`df -h` เหลือ 0 B, `du -sh` พบ Docker.raw ใช้ 30 GB, `docker system df` มี image ที่ไม่ได้ใช้ 7.9 GB	ล้าง cache ที่สร้างใหม่ได้ (Homebrew/npm/Xcode) + `docker image prune -a` + `builder prune` คืนพื้นที่ 10.6 GB แล้ว build ใหม่ผ่าน · ใช้ LocalExecutor (ไม่มี Redis/Celery) และ image เดียวร่วมกัน เพื่อลดขนาด
2. Excel ของ ทปอ. แต่ละปีโครงสร้างไม่เหมือนกัน	ปี 68 มีคอลัมน์ "คะแนนต่ำสุดประมวลผลครั้งที่ 1/2", ปี 69 มี "คะแนนต่ำสุด DS" และ "รหัสโครงการ" เพิ่ม · UPSERT ทับกันเพราะรหัสหลักสูตรซ้ำ	เปิด header ของทุกไฟล์เทียบกัน และนับรหัสหลักสูตรซ้ำ (ปี 69 ซ้ำ 56 รหัส)	เลือกคอลัมน์ด้วย keyword ตัด DS ใช้ผลประมวลผลรอบสุดท้าย · `source_record_id` = รหัสหลักสูตร|รายละเอียด|วิชาเอก|รหัสโครงการ
3. ชื่อหลักสูตรไม่ตรงกันข้ามแหล่ง	"น.บ.(นิติศาสตรบัณฑิต)" ของ ทปอ. ไม่จับคู่กับ "นิติศาสตร์" ของ อว. หลักสูตรจึงแยกเป็น 2 แถว	กรองตารางสรุปหาแถวที่ `n_sources = 1` แต่ชื่อคล้ายกัน	`major_key`: ใช้ข้อความหลัง "สาขาวิชา" หรือชื่อปริญญาในวงเล็บ ตัด "บัณฑิต" ช่องว่าง และไม้ทัณฑฆาต → หลักสูตรที่พบ ≥2 แหล่งเพิ่มเป็น 214
4. ช่องจำนวนรับไม่ใช่ตัวเลข	44 แถวของ admission.ku เขียนว่า "*จำนวนรับรวมกับเงื่อนไขอื่น"	ดู reason ในตาราง `dq_quarantine` แล้วเปิด HTML ของหน้าโครงการ 8	กฎ DQ "ต้องมีจำนวนรับ" แยกไป `quarantine_bad_rows` ไม่นำมานับ เพื่อกันนับที่นั่งซ้ำ

3. การวางแผนและจัดลำดับงาน

เวลา	งาน
13:00–13:55	อ่านโจทย์ แตกเป็น checklist ตามระดับ · สำรวจแหล่งจริงก่อนจอง (ตรวจ robots.txt, ดูว่าเป็น HTML ธรรมดาหรือ JavaScript, นับจำนวนแถว) · เทียบ 3 หัวข้อ แล้วเลือกหัวข้อที่ทั้ง 3 แหล่งเป็น "เรื่องเดียวกัน" จริง → จองในไลน์
14:00–14:10	สร้าง repo ตามชื่อที่กำหนด แล้ว push commit แรกทันที (กันพลาดเรื่อง commit ก่อน 16:00) · เขียน extract 3 แหล่งและทดสอบกับเว็บจริงนอก Docker ก่อน เพื่อลดเวลา debug ใน Airflow
14:10–14:35	เขียน transform / DQ / UPSERT / dashboard ระหว่างแก้ปัญหา Docker และดิสก์เต็ม
14:35–14:45	รัน DAG จริง, trigger ซ้ำเพื่อพิสูจน์ UPSERT, จำลองแหล่งล่ม, แคปหน้าจอ
14:45–15:30	เขียน PDF/README · เผื่อเวลา 30 นาทีท้ายไว้ clone repo ใหม่มารันทดสอบ แล้วส่งงาน

ลำดับความสำคัญ: ทำระดับ 1 ให้ครบทั้งเส้นก่อน แล้วค่อยเพิ่มระดับ 2 → 3 → โบนัส · งานที่ **ตัดออก** และเหตุผล:

- **ข้อมูลตลาดงาน (JobThai/JobBKK):** น่าสนใจ แต่ไม่ใช่ "เรื่องเดียวกัน" กับข้อมูลรับเข้า และต้องทำตาราง mapping สาขาไปเป็นอาชีพเอง เสี่ยงทั้งคะแนนและเวลา
- **สถิติของสำนักบริหารการศึกษา มก.:** เป็น Power BI ฝังในหน้าเว็บ ต้องใช้ browser automation ซึ่งโจทย์ห้าม (Selenium) · ม.บูรพาที่มีหน้าสถิติก็ถูกตัด เพราะ robots.txt ตั้ง `Disallow: /`
- **TCAS ย้อนหลังปี 61–66 และข้อมูล อว. ปี 2563–2564:** รูปแบบคอลัมน์ต่างกันมากขึ้น ใช้ 3 ปีก็พอเห็นแนวโน้มแล้ว จึงเก็บไว้เป็นงานต่อยอด
- **เว็บรับสมัครของวิทยาเขตอื่น:** admission.ku.ac.th แสดงบางเขนเป็นหลัก แต่ข้อมูลวิทยาเขตอื่นยังได้จาก ทปอ. และ อว. ครบ